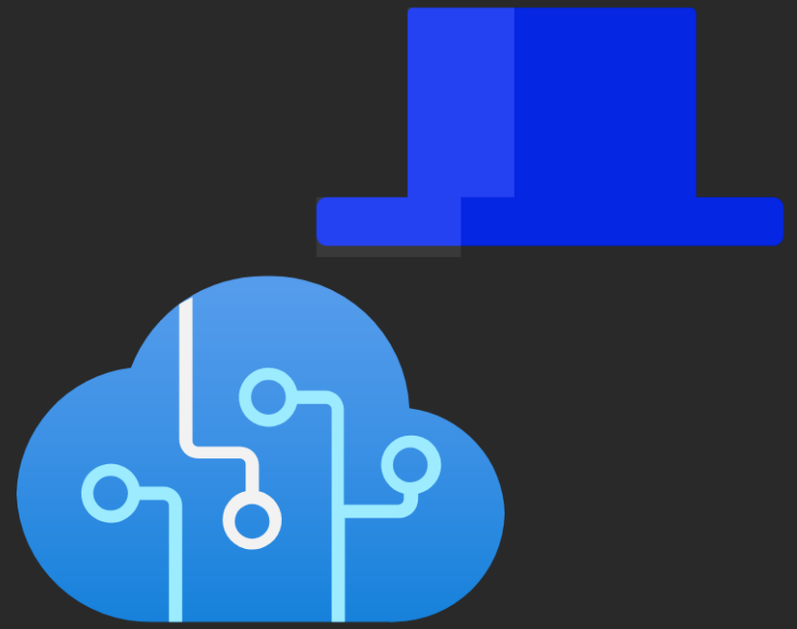
Descomplicando o uso de múltiplas IAs com Dapr e AI Gateways

Renato Groffe
Microsoft MVP, Docker Captain, Grafana Champion
linkedin.com/in/renatogroffe
renatogroffe.medium.com



Renato Groffe



- Microsoft Most Valuable Professional (MVP)
- Docker Captain
- Grafana Champion
- APISEC U Ambassador
- Multi-Plataform Technical Audience Contributor (MTAC)
- Arquiteto de Soluções/Software
- +20 anos de experiência na área de Tecnologia
- Community Leader, Autor Técnico e Palestrante













Conteúdos desta apresentação

github.com/renatogroffe/dapr-ai-services_ai-weekend-2026-10







Agenda

- Desafios no uso de Inteligências Artificiais hoje
- Dapr: uma visão geral e arquitetura
- AI Gateways: segurança e padronização
- Exemplos práticos







Problemas comuns no uso de IAs hoje

- Diferentes soluções contam com **diferentes payloads, métodos de autenticação**...
- Muitas empresas utilizam **mais de uma solução de IA Generativa**
- Novas versões bibliotecas são lançadas diariamente, muitas vezes com **breaking changes**
- Preocupações com **segurança**, em virtude de inúmeros ataques reportados



Alternativas para solucionar isto…

- Dapr (Distributed Application Runtime)
- AI Gateways



O projeto Dapr: uma visão geral

- Distributed Application Runtime
  https://dapr.io/

- **Open source**, **multiplataforma** e com status como **Graduated** – desde **Outubro/2024** – na **CNCF (Cloud Native Computing Foundation)**

- Framework com **Building blocks** para a construção de Microservices e aplicações distribuídas



O projeto Dapr: uma visão geral

- Ambientes baseados em **Kubernetes** ou **máquinas-virtuais** (**Self-hosted mode**)

- O suporte a **Kubernetes** permite que implementações em **Dapr** possam ser projetadas para **qualquer nuvem** ou, mesmo, **ambientes on-premise**

- Soluções serverless como **Azure Container Apps** e **Azure Functions** também possuem integrações



O projeto Dapr: uma visão geral

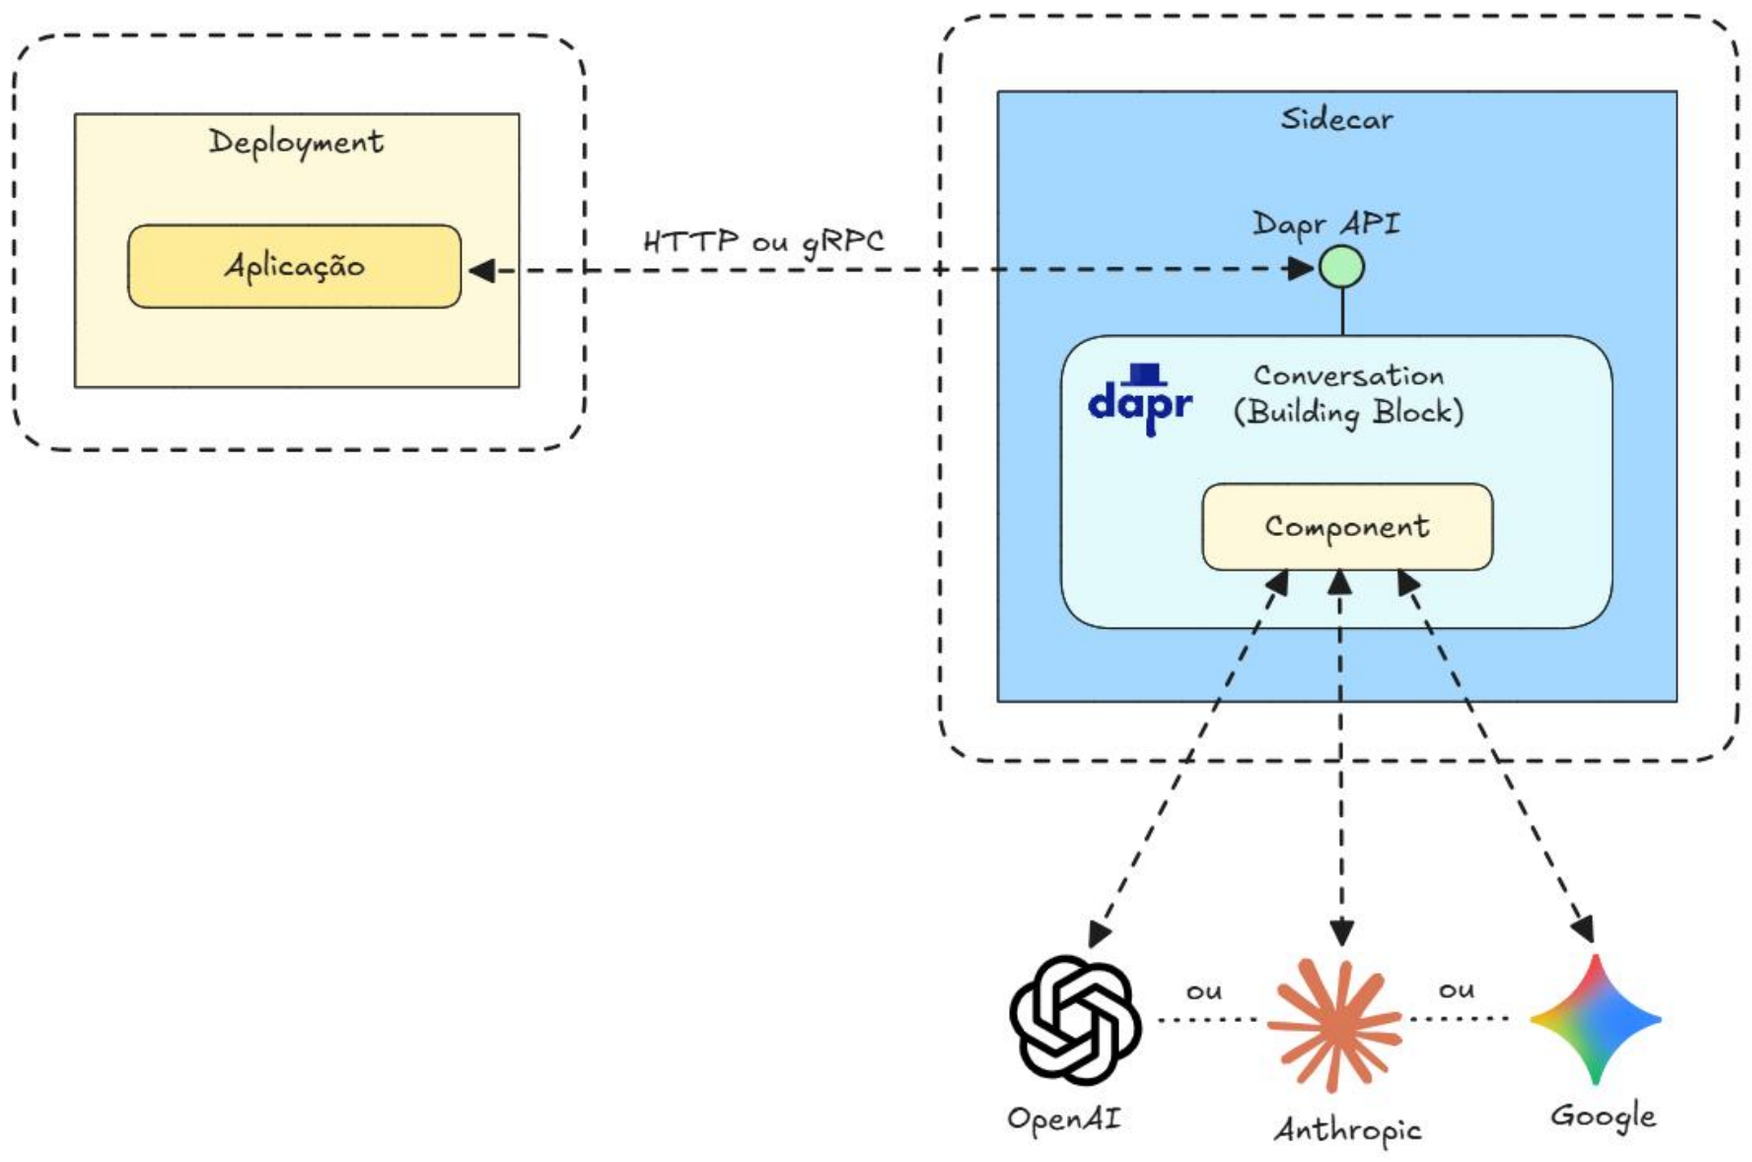
- **Building blocks** são agrupados em um **sidecar** para a aplicação, de forma a simplificar a interação com serviços de apoio
- A configuração dos **building blocks** pode ser feita via **arquivos YAML**
- **Dapr CLI** como ferramenta de desenvolvimento e execução
- A comunicação entre aplicação e sidecar usa os protocolos **gRPC** e **HTTP**



O projeto Dapr: Building blocks



O projeto Dapr: Conversation (IAs Generativas)



O projeto Dapr: benefícios

- Um **maior foco na lógica do negócio** durante a implementação de soluções
- Suporte a múltiplas stacks: **.NET, Java, Python, JavaScript/Node.js, Go, PHP, C++, Rust**
- Fornece uma **padronização** para times que utilizam várias linguagens/plataformas de desenvolvimento



O projeto Dapr: benefícios

- **Produtividade**
- **Integração agnóstica** com serviços de apoio, **incluindo várias IAs**
- Uma alternativa bem interessante para **desenvolvimento de produtos** e **soluções SaaS (Software as a Service)** que ofereçam o suporte a múltiplos serviços/tecnologias de apoio similares



O que é um AI Gateway?

- Ponto central de acesso aos modelos de IA
- Centraliza chamadas para diferentes provedores
- Abstrai detalhes dos modelos e APIs
- Aplica políticas antes das requisições
- Facilita o gerenciamento de aplicações de IA



Por que utilizar um AI Gateway?

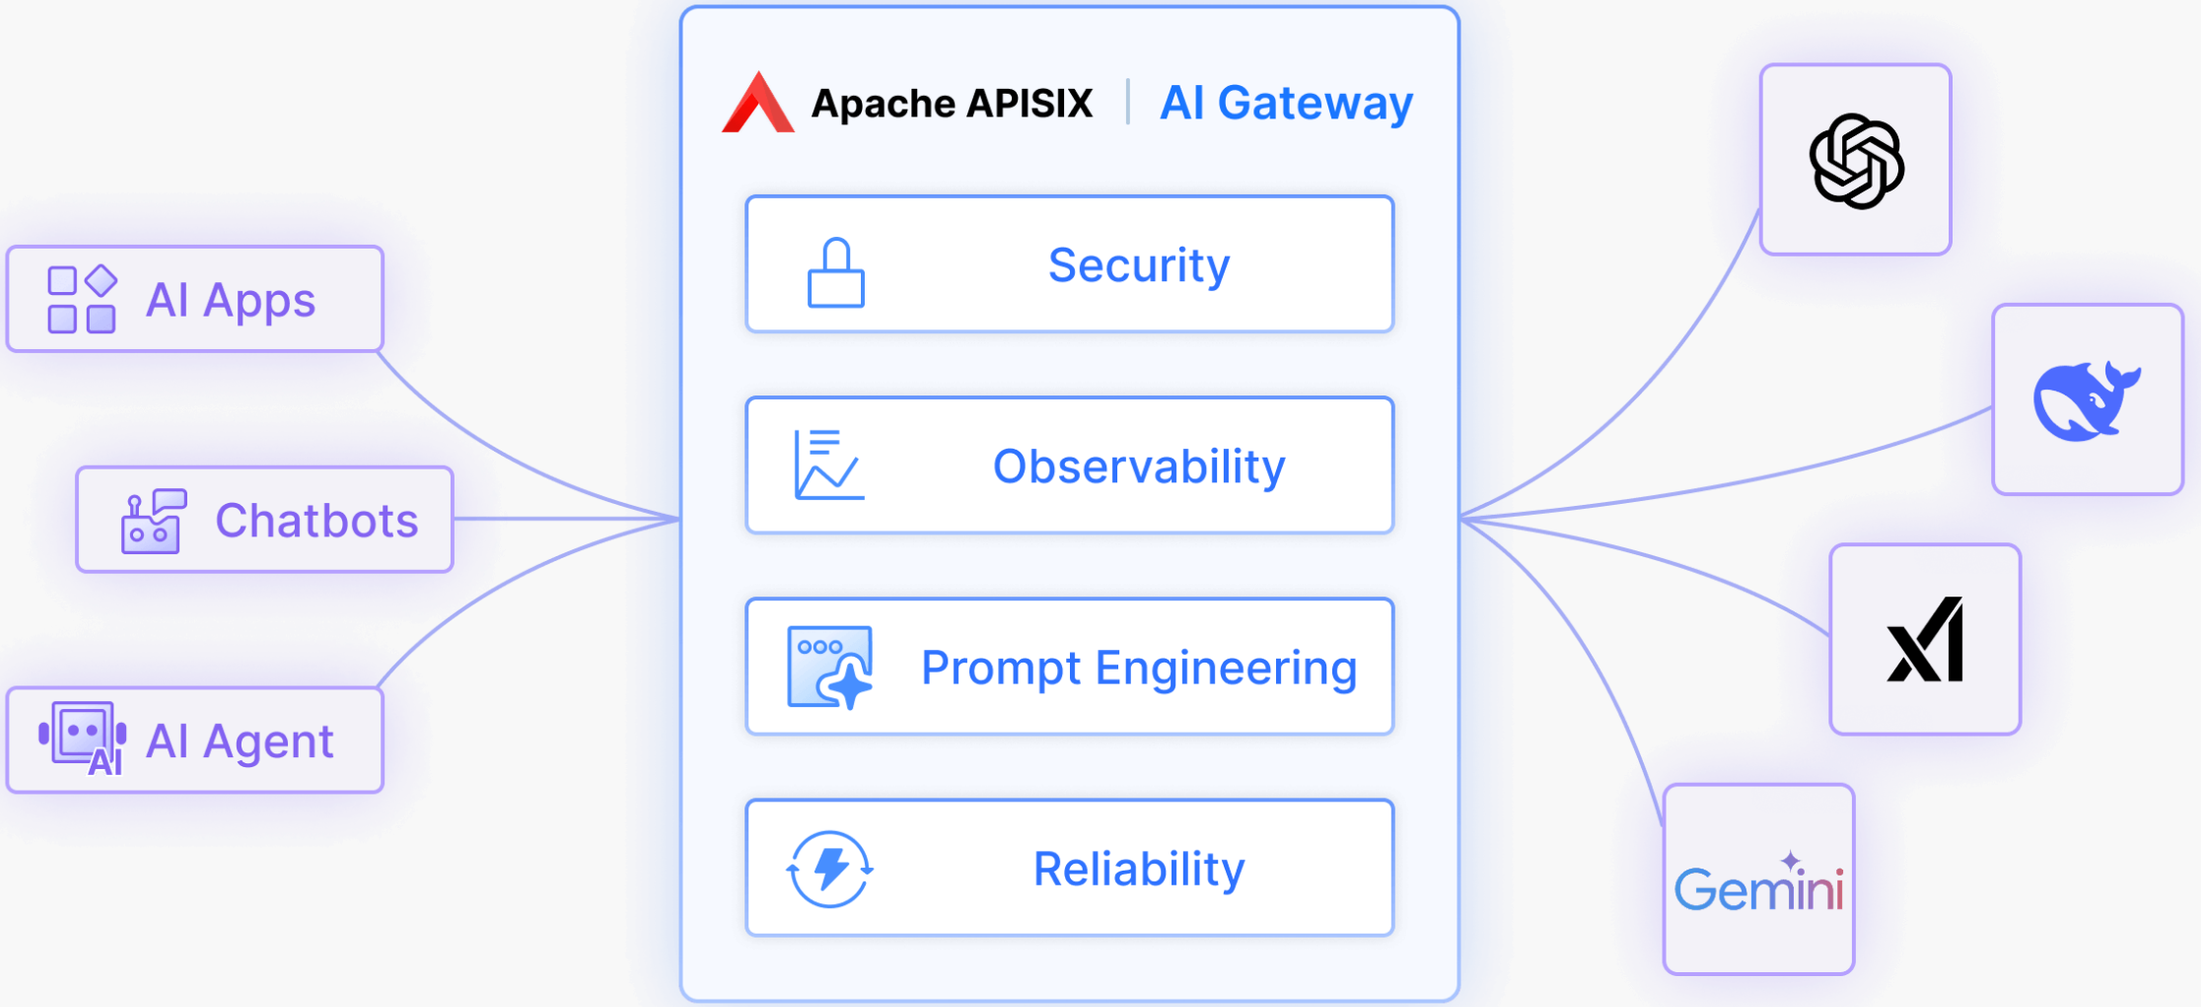
- **Segurança**: controle de acesso e proteção das APIs
- **Governança**: políticas centralizadas para uso de IA
- **Observabilidade**: métricas, logs e rastreamento
- **Custos**: controle e acompanhamento do consumo
- **Flexibilidade**: troca de modelos sem alterar aplicações

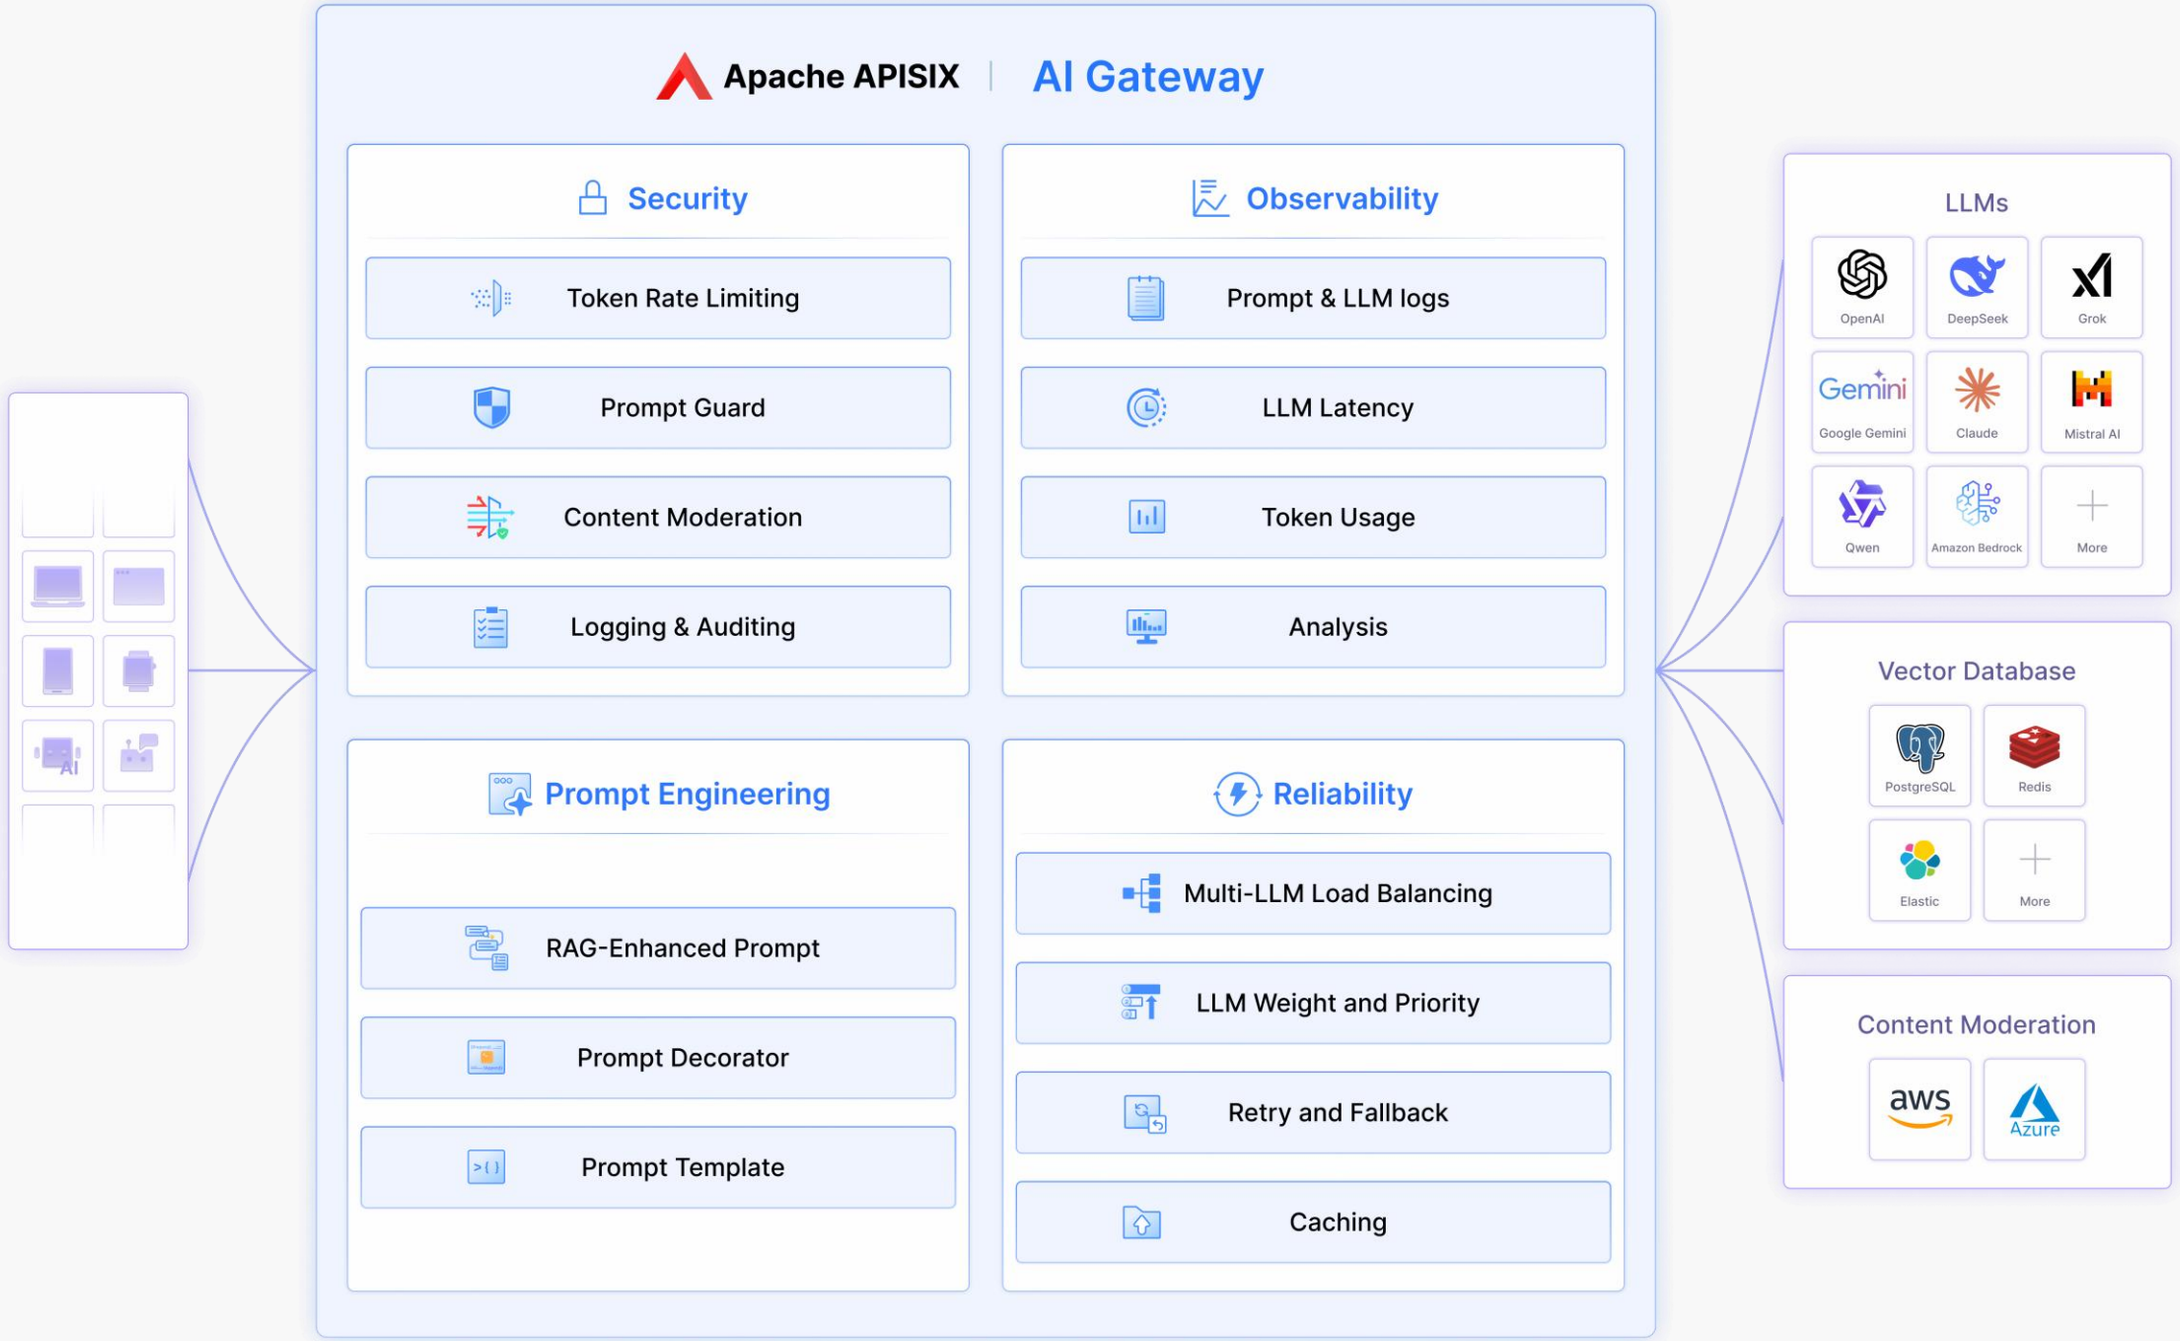


AI Gateways: algumas alternativas

- APISIX
- Azure API Management (APIM)
- Azure AI Gateway
- Kong
- LiteLLM
- ....




AI Apps
Chatbots
AI Agent
Apache APISIX | AI Gateway
Security
Observability
Prompt Engineering
Reliability
Gemini


Apache APISIX | AI Gateway
Security
Token Rate Limiting
Prompt Guard
Content Moderation
Logging & Auditing
Observability
Prompt & LLM logs
LLM Latency
Token Usage
Analysis
Prompt Engineering
RAG-Enhanced Prompt
Prompt Decorator
Prompt Template
Reliability
Multi-LLM Load Balancing
LLM Weight and Priority
Retry and Fallback
Caching
LLMs
OpenAI
DeepSeek
Grok
Gemini
Google Gemini
Claude
Mistral AI
Qwen
Amazon Bedrock
More
Vector Database
PostgreSQL
Redis
Elastic
More
Content Moderation
aws
Azure

EXEMPLOS PRÁTICOS



OBRIGADO!

